Aprendizado Federado Privado com DP-SGD para Detecção de Fraude: Avaliando o *Trade-off* Utilidade vs. Privacidade com Validação por *Membership Inference Attack*

Bernardo Borges (2023111115), Júlia Borba (2023117580), Laura Froede (2023087877), Leonardo César (2023087923)

Departamento de Ciência da Computação
Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte – MG, Brasil

23 de junho de 2026

Resumo

Este trabalho investiga o *trade-off* entre utilidade preditiva e privacidade em *Privacy-Preserving Machine Learning* (PPML) na detecção de fraudes em cartões de crédito. Utilizamos o ecossistema Flower e a biblioteca Opacus para avaliar três arquiteturas sob o mesmo pipeline: centralizada (V1), federada pura (V2) e federada com privacidade diferencial local via DP-SGD (V3). Adicionamos também um *baseline* de modelos locais isolados como piso de desempenho. Os modelos operam sob severo desbalanceamento de classes ($\approx 0,17\%$ de fraude) e heterogeneidade Não-IID (Dirichlet, $\alpha = 0,5$). A privacidade foi auditada por meio de um *Membership Inference Attack* (MIA) baseado em limiar de perda, focado na classe minoritária. Os resultados de cinco sementes mostram que a federação (V2, PR-AUC $0,809 \pm 0,043$) iguala o teto centralizado (V1, $0,811 \pm 0,022$) sem o compartilhamento de dados brutos. Além disso, supera o desempenho dos bancos treinados isoladamente ($0,727 \pm 0,084$, com ganho pareado de $+0,082$), confirmando a vantagem da colaboração. Observamos que o termo proximal do FedProx ($\mu > 0$) não trouxe ganhos e chegou a desestabilizar o treino em $\mu = 0,1$; como utilizamos apenas uma época local, o *client drift* é insuficiente para justificar essa correção. A aplicação de Privacidade Diferencial reduziu o *advantage* do MIA na fraude (V1 $0,151 \rightarrow$ V2 $0,124 \rightarrow$ V3 $\approx 0,11$), custando cerca de $0,15$ na PR-AUC. O ganho de privacidade saturou em $\varepsilon = 5$, atingindo o piso de ruído estatístico. Valores mais estritos, como $\varepsilon = 1$, introduziram variância destrutiva sem benefícios mensuráveis, consolidando $\varepsilon \approx 5$ como o ponto de operação ideal. Também registramos um modo de falha catastrófico em uma das sementes (PR-AUC $\approx 0,003$ sob DP), ilustrando os limites práticos da imposição de privacidade severa em partições Não-IID patológicas.

Palavras-chave: Aprendizado Federado, Privacidade Diferencial, DP-SGD, Membership Inference Attack, Detecção de Fraudes, Dados Não-IID, Client Drift.

1. Introdução

A digitalização dos sistemas financeiros globais e a consequente expansão dos meios de pagamento eletrônicos trouxeram consigo um aumento expressivo nas tentativas de transações fraudulentas, resultando em perdas financeiras bilionárias anualmente. Para mitigar esse cenário, o desenvolvimento de modelos preditivos baseados em aprendizado profundo tornou-se indispensável. Contudo, a engenharia desses modelos enfrenta barreiras regulatórias impostas por legislações modernas de proteção de dados, tais como a Lei Geral de Proteção de Dados (LGPD) no Brasil e a *General Data Protection Regulation* (GDPR) na União Europeia.

Historicamente, o treinamento de detectores de fraude robustos exigia a centralização massiva de registros históricos em um único servidor. No entanto, instituições financeiras concorrentes encontram óbices de segredo comercial e restrições legais para compartilhar suas bases brutas. Cria-se, portanto, um dilema fundamental: modelos treinados localmente e de forma isolada sofrem com a escassez crônica de dados (especialmente da classe fraudulenta, inerentemente rara), ao passo que a centralização irrestrita de dados sensíveis infringe diretamente o direito à privacidade dos usuários.

O Aprendizado Federado (FL) desponta como um paradigma promissor para solucionar esse impasse, viabilizando o treinamento colaborativo de modelos globais sem que os dados locais jamais deixem os seus servidores de origem. Contudo, a literatura demonstra que o FL por si só não confere proteção absoluta [Mothukuri et al., 2021]. Os parâmetros atualizados compartilhados pelos clientes durante as rodadas de comunicação retêm uma pegada de memória dos dados locais. Um adversário pode interceptar esses *updates* e, por meio de ataques algorítmicos, inferir se um registro específico fez parte do conjunto de treinamento [Shokri et al., 2017].

É crucial evidenciar que técnicas clássicas de anonimização superficial são insuficientes diante de adversários algorítmicos. No dataset de referência da Universidade Livre de Bruxelas (ULB), os dados brutos foram previamente submetidos à Análise de Componentes Principais (PCA), ocultando variáveis explícitas sob colunas anônimas indexadas de V_1 a V_{28}. Apesar disso, um algoritmo espião focado em comportamento de perda desconsidera completamente a legibilidade humana das colunas, operando diretamente sobre a memória do modelo. A privacidade real exige salvaguardas matemáticas que limitem o impacto de qualquer indivíduo na saída final do sistema.

Este trabalho aborda de forma experimental o ecossistema de detecção de fraude, avaliando o *trade-off* utilidade vs. privacidade através de três hipóteses de trabalho:

1. **Hipótese 1:** O Aprendizado Federado colaborativo supera o desempenho preditivo de modelos locais treinados isoladamente, mitigando a escassez local de dados.

2. **Hipótese 2:** Algoritmos com mecanismos de mitigação de desvio proximal (como o FedProx) exibem superioridade e estabilidade em relação ao *Federated Averaging* (FedAvg) sob distribuições altamente heterogêneas (Não-IID).

3. **Hipótese 3:** A integração de Privacidade Diferencial local via DP-SGD reduz a vulnerabilidade do modelo a ataques de inferência de filiação (MIA), mantendo um custo de utilidade previsível e controlado.

Adiantamos que os experimentos confirmam a Hipótese 1, refutam a Hipótese 2 e confirmam parcialmente a Hipótese 3, conforme detalhado na Seção 5.

2. Trabalhos Relacionados e Estado da Arte

A intersecção entre Aprendizado Federado, Privacidade Diferencial e segurança em dados tabulares altamente desbalanceados tem sido alvo de intensa investigação na comunidade de PPML (*Privacy-Preserving Machine Learning*).

O estudo desenvolvido em Wasif et al. [2025] contextualiza a aplicação do aprendizado federado sob modelos de ameaça ativos, nos quais até 10% dos nós participantes podem agir de maneira maliciosa. Os autores demonstram que a heterogeneidade estatística dos dados atua como um amplificador natural de variância, elevando os riscos de vazamento e degradação do modelo. O trabalho preconiza o uso de simulações controladas de ataques (como o MIA) durante a fase de *design* para mapear a Fronteira de Pareto ideal do sistema.

Paralelamente, a pesquisa Gulipalli et al. [2026] avaliou um cenário composto por 5 instituições bancárias totalizando 200.000 registros, mapeando o impacto da DP no equilíbrio de métricas. Os resultados reportados estabelecem que modelos puramente locais e isolados sofrem de severa subotimização, atingindo um F1-Score médio de apenas $0,65$. A colaboração via FedAvg puro eleva essa métrica para $0,91$. Contudo, ao incorporar restrições formais de privacidade, o desempenho decai progressivamente: para um épsilon frouxo ($\varepsilon = 10$), o F1-Score recua para $0,88$, atingindo $0,79$ quando a privacidade é estrita ($\varepsilon = 1$). Esses achados validam a premissa de que a segurança matemática impõe um custo de utilidade que deve ser cuidadosamente calibrado.

Por fim, Sanyal et al. [2022] fornece a intuição fundamental para os modos de falha em distribuições desbalanceadas. Os autores provam matematicamente que o ruído aditivo necessário para mascarar a contribuição de um indivíduo possui um efeito colateral assimétrico: ele penaliza desproporcionalmente as classes minoritárias e os subgrupos sub-representados. Sob essa ótica, o ruído que protege a identidade do cliente é matematicamente o mesmo que cega a rede neural para a identificação de sinais raros, estabelecendo os limites da combinação dessas técnicas no mundo real, um fenômeno que reproduzimos empiricamente na Seção 5.6.

3. Fundamentação Teórica e Formulação Matemática

3.1. Aprendizado Federado e o Algoritmo FedAvg

No paradigma do Aprendizado Federado estabelecido pelo algoritmo *Federated Averaging* (FedAvg) [McMahan et al., 2017], a otimização distribui-se ao longo de R rodadas globais de comunicação. Considere K clientes (instituições bancárias), onde cada cliente possui um dataset local $\mathcal{D}_k$ de tamanho n_k, sendo $N = \sum n_k$. O servidor inicializa os parâmetros globais como $w^{(0)}$. A cada rodada r, o servidor transmite o estado corrente $w^{(r)}$ aos nós. Cada cliente inicializa $w_k^{(r,0)} = w^{(r)}$ e executa E épocas de gradiente descendente estocástico (SGD) para minimizar sua perda local $F_k(w)$:

$$w_k^{(r,e+1)} = w_k^{(r,e)} - \eta \nabla F_k(w_k^{(r,e)}) \tag{1}$$

Ao término do treinamento local, cada nó devolve $w_k^{(r,E)}$ ao servidor, que realiza a agregação por média ponderada pelo volume de amostras:

$$w^{(r+1)} = \sum_{k=1}^{K} \frac{n_k}{N} w_k^{(r,E)} \tag{2}$$

Neste trabalho, fixamos $E = 1$ época local por rodada e $R = 15$ rodadas. Trata-se de uma escolha de projeto deliberada: a comunicação frequente maximiza a estabilidade da agregação sob heterogeneidade severa, mantendo os clientes fortemente sincronizados ao consenso global e minimizando o *client drift* entre rodadas (ver Seção 4).

3.2. Heterogeneidade Estatística e a Dinâmica do Client Drift

Sob condições Não-IID [Zhao et al., 2018], as perdas locais $F_k(w)$ refletem distribuições marcadamente distintas, possuindo mínimos $\arg\min F_k(w)$ distantes entre si e desalinhados com o mínimo da perda global $F(w) = \sum \frac{n_k}{N} F_k(w)$. O fenômeno do *Client Drift* surge quando os nós executam múltiplos passos locais ($E \gg 1$) sem comunicação intermediária: ao otimizar agressivamente em direção ao seu ótimo local, a trajetória de cada cliente diverge, e a média de atualizações divergentes aponta para uma direção subótima, retardando a convergência.

Para conter essa deriva, o algoritmo **FedProx** [Li et al., 2020] reformula a otimização local introduzindo uma penalidade proximal quadrática:

$$\mathcal{L}_{Local}(w) = F_k(w) + \frac{\mu}{2} \|w - w^{(r)}\|^2 \tag{3}$$

Onde $w^{(r)}$ é a âncora do modelo global recebida no início da rodada e $\mu \geq 0$ regula a intensidade da restrição. O gradiente do termo proximal é $\mu(w - w^{(r)})$. Geometricamente, o termo funciona como uma corda elástica que penaliza trajetórias locais que se afastem do consenso da rodada anterior, mitigando o *client drift*. Cumpre observar, antecipando a discussão experimental, que a eficácia do FedProx é condicional à existência de *drift* relevante; sob $E = 1$ época local, como adotado aqui, o *drift* é intrinsecamente reduzido.

3.3. Privacidade Diferencial Local via DP-SGD

A Privacidade Diferencial (DP) estabelece um limite estrito para o quanto a inclusão ou exclusão de um único registro pode alterar a distribuição das saídas do algoritmo. No treinamento de redes neurais, o DP-SGD operacionaliza essa garantia modificando o cálculo dos gradientes. Para cada amostra i em um lote B, computa-se o gradiente individualizado $g_i(w) = \nabla_w \ell(x_i, y_i; w)$, e executam-se duas etapas:

1. **Recorte por Norma (Clipping):** restringe a sensibilidade do gradiente por amostra impondo um teto C:

$$\bar{g}_i(w) = g_i(w) \cdot \min\left(1, \frac{C}{\|g_i(w)\|_2}\right) \tag{4}$$

2. **Injeção de Ruído Gaussiano:** insere aleatoriedade controlada na soma dos gradientes clipados:

$$\tilde{g}(w) = \frac{1}{|B|}\left(\sum_{i \in B} \bar{g}_i(w) + \mathcal{N}\left(0, \sigma^2 C^2 \mathbb{I}\right)\right) \tag{5}$$

Onde σ é o multiplicador de ruído. O rastreamento do orçamento de privacidade (ε, δ) baseia-se em *Rényi Differential Privacy* (RDP). Em arquiteturas federadas heterogêneas, fixar um σ idêntico para todos os clientes induz gastos assimétricos de privacidade, pois

o consumo de ε depende da taxa de amostragem local $q_k = |B|/n_k$ e do número total de passos $T_k = R \cdot E \cdot (n_k/|B|)$. Clientes com bases menores exibem taxas q_k elevadas, acelerando o consumo de ε. Para garantir proteção uniforme, implementamos o mecanismo de **Back-solving do** σ: o sistema recebe o ε global alvo e resolve numericamente, de forma inversa, a equação do contador RDP para cada cliente, definindo o multiplicador σ_k sob medida para a sua cardinalidade local.

3.4. Mecanismo do Membership Inference Attack (MIA)

O ataque de inferência de filiação avalia empiricamente a resiliência de privacidade do sistema atuando como auditor adverso. Sob o modelo de Yeom et al. [Yeom et al., 2018], o ataque baseia-se no pressuposto de que modelos de aprendizado profundo minimizam a perda de maneira mais acentuada em amostras de treino do que em registros inéditos. O atacante possui acesso a um conjunto dividido entre membros ($\mathcal{M}$, presentes no treino) e não-membros ($\mathcal{M}'$, ausentes). Para cada vetor (x_i, y_i), calcula a perda *Cross-Entropy* Binária (BCE) por amostra não-ponderada ℓ_i e define o *score* de pertinência $s_i = -\ell_i$. A regra de decisão é por limiar: se $s_i > \tau$, prediz membro; caso contrário, não-membro. O sucesso é mensurado via *Membership Advantage*:

$$\text{Adv} = \max_{\tau} \left(\text{TPR}(\tau) - \text{FPR}(\tau)\right) \tag{6}$$

Onde $\text{TPR}(\tau)$ e $\text{FPR}(\tau)$ são as taxas de verdadeiros e falsos positivos do atacante. Como o vazamento se concentra na classe rara (Seção 5), reportamos o *advantage* com recorte na classe de fraude: medido sobre todo o conjunto, o ataque opera próximo ao acaso, pois o modelo generaliza bem na classe majoritária.

4. Metodologia Experimental e Implementação

4.1. Características do Dataset e Ingestão Estratificada

A validação utiliza o dataset público ULB Kaggle `creditcard.csv`, composto por 284.807 transações com 30 atributos numéricos obtidos via PCA. O conjunto exibe desbalanceamento crítico, abrigando apenas 492 fraudes ($\approx 0,17\%$). Aplicamos divisão estratificada determinística, particionando o volume em 70% para treino (199.364 amostras, 344 fraudes), 15% para validação (42.721 amostras, 74 fraudes) e 15% para teste (42.722 amostras, 74 fraudes). O escalonador estatístico foi ajustado exclusivamente na base de treino.

Para forçar um ambiente realista, o conjunto de treino foi particionado entre $K = 3$ clientes virtuais por uma distribuição de Dirichlet parametrizada por $\alpha = 0,5$. O sorteio resultou em um cenário Não-IID severo de *label-skew*, detalhado na Tabela 1 (semente 42).

Tabela 1: Distribuição Heterogênea Não-IID via Dirichlet ($\alpha = 0,5$, semente 42).

Cliente Virtual	Nº de Amostras	Nº de Fraudes	Taxa Local de Fraude	Fatia das Fraudes
Banco 0	79.619	19	$0,024\%$	$5,5\%$
Banco 1	87.584	72	$0,082\%$	$20,9\%$
Banco 2	**32.161**	**253**	$\mathbf{0,787\%}$	$\mathbf{73,5\%}$

4.2. Arquitetura da Rede Neural e Restrições do Sistema

O modelo preditivo compartilha uma topologia MLP idêntica e congelada nas versões V1, V2 e V3, bem como nos modelos isolados, estruturada conforme o fluxo:

$$\text{Entrada } (30) \to \text{Linear}(30 \to 128) \to \text{LayerNorm}(128) \to \text{ReLU} \to \text{Dropout}(0,05)$$

$$\to \text{Linear}(128 \to 64) \to \text{LayerNorm}(64) \to \text{ReLU} \to \text{Dropout}(0,05) \to \text{Linear}(64 \to 1)$$

O nó final emite um único *logit* bruto. A utilização de camadas de *Batch Normalization* foi vetada em todas as variantes para assegurar compatibilidade e equivalência estrita de pipeline (*apples-to-apples*) com o motor DP-SGD do Opacus, que requer isolamento de gradientes por amostra. Substituiu-se pelo **LayerNorm**, que normaliza ao longo da dimensão das *features* de cada registro isolado. O otimizador é o **AdamW** em todas as variantes. A taxa de *dropout* foi mantida deliberadamente baixa $(0,05)$, já que valores mais agressivos (e.g., $0,2$) regularizavam em excesso e apagavam o tênue sinal da classe de fraude, deprimindo a PR-AUC. Pela mesma lógica de preservação do sinal raro, manteve-se a ativação ReLU após experimentos com a GELU, que degradou a utilidade sem oferecer ganho compensatório de privacidade.

4.3. Calibração do pos_weight e Política de Limiar

Em virtude do desbalanceamento extremo, a perda *Cross-Entropy* incorpora o hiperparâmetro `pos_weight` (w^+) para penalizar erros na classe minoritária. O valor analítico convencional ($w^+ = n_{\text{neg}}/n_{\text{pos}} \approx 577$) mostrou-se prejudicial em testes preliminares, porque inflava excessivamente os *logits*, achatando o gradiente de confiança necessário para a ordenação dos *scores*. Fixou-se empiricamente `pos_weight` $= 25$, otimizando a Área Sob a Curva Precision-Recall (PR-AUC), métrica primária de utilidade deste estudo. A conversão dos *logits* em decisões binárias opera sob isolamento estrito de validação: a curva Precision-Recall é computada sobre os dados de validação, elegendo-se o limiar $\tau^\star$ que maximiza o F1-Score; esse limiar é congelado e reaplicado de forma cega sobre o teste, separadamente por cenário e por semente.

4.4. Protocolo Experimental Multi-semente

Para robustez estatística, todo o circuito é executado de forma pareada sobre cinco sementes saudáveis $[42, 43, 44, 45, 47]$, regenerando *split*, partição e conjuntos do MIA em memória por semente. Reportamos Média $\pm$ Desvio-Padrão. O conjunto de avaliação do MIA é fixo e balanceado, composto por 2.000 membros (do treino) e 2.000 não-membros (do teste), com a mesma composição de classe nos dois grupos ($\approx 3,7\%$ de fraude). Exploramos duas dimensões de varredura: o parâmetro proximal do FedProx $\mu \in \{0; 0,01; 0,1\}$ (com $\mu = 0 \Rightarrow$ FedAvg puro) e o orçamento de privacidade do V3 $\varepsilon \in \{1; 5\}$ (com $\delta = 10^{-5}$ e teto de *clipping* $C = 1$).

Adicionalmente, para aferir a Hipótese 1, treinamos um *baseline* de modelos isolados: um modelo independente por banco, treinado exclusivamente sobre a partição local, pelo mesmo total de épocas que cada cliente recebe na federação ($R \cdot E = 15$), e avaliado sobre o mesmo conjunto de teste global com a mesma política de limiar. Esse cenário estabelece o piso de desempenho contra o qual o ganho da colaboração é medido.

4.5. Arquitetura de Coexistência no V3: FedProx e Opacus

A integração simultânea do FedProx com o motor de privacidade do Opacus introduz uma incompatibilidade de engenharia. O gradiente proximal $\mu(w - w^{(r)})$ depende apenas de parâmetros do modelo corrente e do estado global público da rodada, sem vínculo com dados sensíveis. Se adicionado à perda antes do `backward()` do Opacus, o sistema tentaria calcular gradientes por amostra sobre um termo sem dimensão de lote, resultando em falha de execução ou em *clipping*/ruído indevidos sobre termos públicos, corrompendo a contabilidade do ε.

Solucionamos esse impasse invocando o princípio de imunidade ao pós-processamento da Privacidade Diferencial. No V3, o `backward()` é calculado exclusivamente sobre a perda dos dados brutos, acionando o `optimizer.pre_step()` do Opacus para clipar e ruidar o gradiente sensível. Imediatamente após a consolidação do gradiente privatizado, interceptamos o vetor e injetamos manualmente o gradiente proximal público; o otimizador original executa o passo final (`step()`) sobre a composição híbrida. Como o termo proximal é função apenas de quantidades públicas, ele não é clipado nem ruidado e não consome orçamento de privacidade, preservando exata a contabilidade do ε e garantindo a coexistência harmônica dos algoritmos.

5. Resultados e Discussões

5.1. Análise Comparativa Global

Os resultados consolidados sobre as cinco sementes saudáveis [42, 43, 44, 45, 47] encontram-se na Tabela 2. Nenhum dos cenários do grid principal colapsou (5/5 sementes válidas em todas as linhas). A métrica primária é a PR-AUC no teste; a coluna *MIA-Fraude Adv.* reporta o *advantage* do atacante restrito à classe de fraude.

Tabela 2: Resultados Consolidados do Sistema (Média ± Desvio-Padrão no Teste, 5 sementes).

Cenário ($\alpha = 0,5$)	ε	PR-AUC	Recall	Precision	F1-Score	MIA-Fraude Adv.
V1 Centralizado	—	$\mathbf{0,811 \pm 0,022}$	$0,786 \pm 0,041$	$0,821 \pm 0,060$	$0,802 \pm 0,033$	$0,151 \pm 0,046$
V2 FedAvg ($\mu = 0$)	∞	$0,809 \pm 0,043$	$0,797 \pm 0,043$	$0,789 \pm 0,072$	$0,792 \pm 0,049$	$0,124 \pm 0,062$
V2 FedProx ($\mu = 0,01$)	∞	$0,793 \pm 0,029$	$0,789 \pm 0,059$	$0,801 \pm 0,038$	$0,794 \pm 0,036$	$0,143 \pm 0,078$
V2 FedProx ($\mu = 0,1$)	∞	$0,706 \pm 0,076$	$0,811 \pm 0,032$	$0,783 \pm 0,057$	$0,795 \pm 0,031$	$0,108 \pm 0,097$
V3 DP ($\mu = 0$)	5	$\mathbf{0,658 \pm 0,074}$	$0,786 \pm 0,029$	$0,805 \pm 0,040$	$0,795 \pm 0,031$	$0,108 \pm 0,092$
V3 DP ($\mu = 0,01$)	5	$0,659 \pm 0,071$	$0,789 \pm 0,033$	$0,806 \pm 0,045$	$0,797 \pm 0,033$	$0,100 \pm 0,108$
V3 DP ($\mu = 0,1$)	5	$0,480 \pm 0,255$	$0,551 \pm 0,234$	$0,567 \pm 0,238$	$0,543 \pm 0,238$	$0,122 \pm 0,095$
V3 DP ($\mu = 0$)	1	$0,634 \pm 0,080$	$0,762 \pm 0,040$	$0,807 \pm 0,052$	$0,784 \pm 0,044$	$0,116 \pm 0,065$
V3 DP ($\mu = 0,01$)	1	$0,646 \pm 0,077$	$0,762 \pm 0,050$	$0,808 \pm 0,045$	$0,783 \pm 0,036$	$0,105 \pm 0,085$
V3 DP ($\mu = 0,1$)	1	$0,455 \pm 0,260$	$0,514 \pm 0,235$	$0,546 \pm 0,271$	$0,519 \pm 0,259$	$0,116 \pm 0,090$

5.2. Hipótese 1: Colaboração Federada vs. Modelos Isolados

Para estabelecer o piso de desempenho, treinamos um modelo independente por banco apenas com seus dados locais. A Tabela 3 apresenta os resultados. A média sobre todos os modelos isolados ($0,727 \pm 0,084$) situa-se nitidamente abaixo da federação. Embora as barras de erro marginais aparentem sobreposição, a comparação pareada por semente (a federação versus a média dos bancos isolados na mesma semente) revela um ganho de $+\mathbf{0,082 \pm 0,023}$ de PR-AUC, com a federação vencendo em 5 de 5 sementes (teste t

pareado $\approx 7,9$; $p < 0,005$). A sobreposição marginal decorre da variância *entre* sementes, que se cancela na comparação pareada.

Tabela 3: *Baseline* de Modelos Isolados (Média ± DP no teste global). O Banco 0, com apenas ≈ 19 fraudes locais, é o mais instável (maior desvio).

Cenário	PR-AUC	Recall	Precision	F1-Score
Banco 0 isolado	$0,715 \pm 0,113$	$0,773 \pm 0,031$	$0,812 \pm 0,048$	$0,791 \pm 0,032$
Banco 1 isolado	$0,706 \pm 0,059$	$0,789 \pm 0,061$	$0,801 \pm 0,019$	$0,794 \pm 0,029$
Banco 2 isolado	$0,760 \pm 0,080$	$0,778 \pm 0,062$	$0,781 \pm 0,049$	$0,777 \pm 0,026$
Isolado (média)	$\mathbf{0,727 \pm 0,084}$	$0,780 \pm 0,050$	$0,798 \pm 0,040$	$0,787 \pm 0,028$

Confirma-se, portanto, a Hipótese 1. Adicionalmente, a federação não apenas supera o piso isolado, como também iguala o teto centralizado: a variante V2 (FedAvg) obteve PR-AUC de $0,809 \pm 0,043$, estatisticamente indistinguível do V1 centralizado ($0,811 \pm 0,022$). Esse comportamento evidencia que a média ponderada do FedAvg atua como mecanismo de regularização implícita: ao fundir parâmetros ajustados em partições Não-IID distintas, o servidor amortece os sobreajustes locais especializados de cada banco, gerando um modelo global com forte capacidade de generalização — e tudo isso sem que os dados brutos deixem suas origens.

5.3. Hipótese 2: O FedProx Não Supera o FedAvg neste Regime

Contrariando a Hipótese 2, a varredura do parâmetro proximal μ não evidencia superioridade do FedProx. No cenário federado puro (V2), a configuração de melhor utilidade é justamente $\mu = 0$ (FedAvg puro, PR-AUC $0,809$); o aumento para $\mu = 0,01$ é estatisticamente equivalente ($0,793$), e $\mu = 0,1$ degrada severamente a utilidade ($0,706$). O mesmo padrão se repete no V3: para ambos os orçamentos $\varepsilon \in \{1; 5\}$, valores elevados de μ provocam colapso parcial da PR-AUC (de $\approx 0,65$ para $\approx 0,48$, com desvio-padrão explosivo de $\pm 0,25$).

A penalidade proximal só agrega valor quando há *client drift* significativo a ser corrigido, isto é, quando os clientes se afastam do consenso ao longo de muitos passos locais. Como adotamos uma única época local por rodada ($E = 1$), os clientes permanecem fortemente ancorados ao modelo global a cada rodada, e o *drift* é mínimo. Nesse regime, o termo proximal apenas adiciona um viés que "engessa" o aprendizado em direção a um modelo desatualizado, prejudicando a convergência em vez de estabilizá-la. Refuta-se, portanto, a Hipótese 2 nas condições experimentais adotadas.

5.4. Hipótese 3: O Trade-off da Privacidade Diferencial

A introdução do ruído de privacidade no V3 penaliza a qualidade de ordenação de *scores*, recuando a PR-AUC de $\approx 0,81$ (V2) para a faixa de $\approx 0,63$–$0,66$ (V3). A Tabela 4 ilustra a calibração do *back-solving* do σ: o cliente com menor volume de amostras totais (Banco 2) recebe o maior multiplicador de ruído ($\sigma = 0,8356$) para compensar sua elevada taxa de amostragem, e o orçamento ε alvo é atingido com precisão ($\varepsilon \approx 4,996$ para o alvo 5; $\varepsilon \approx 0,997$ para o alvo 1).

Tabela 4: Calibração por *back-solving* do multiplicador de ruído σ_k por cliente (alvo $\varepsilon = 5$, semente 42).

Cliente	Nº Amostras	Taxa de Amostragem	Passos Totais	σ Calculado	ε Atingido
Banco 0	79.619	0,00643	2.333	0,7004	4,994
Banco 1	87.584	0,00585	2.566	0,6894	4,995
Banco 2	**32.161**	**0,01592**	**942**	**0,8356**	**4,996**

Quanto ao ponto de operação, os dois orçamentos avaliados comportam-se de forma instrutiva. Com $\varepsilon = 5$, a utilidade (0,658) é equivalente à de $\varepsilon = 1$ (0,634) dentro do desvio-padrão, mas $\varepsilon = 1$ exibe variância marcadamente maior e instabilidade incipiente. Sob a ótica de engenharia, afrouxar a privacidade de $\varepsilon = 1$ para $\varepsilon = 5$ não custa utilidade mensurável e ainda estabiliza o treino; em contrapartida, apertar abaixo de $\varepsilon = 5$ injeta variância sem retorno de proteção mensurável. Elege-se $\varepsilon \approx 5$ como ponto de operação na Fronteira de Pareto.

A auditoria empírica via MIA corrobora a leitura, com uma ressalva honesta. A ativação do DP-SGD reduz o *advantage* do atacante na classe de fraude na direção esperada, consistente com a Privacidade Diferencial como defesa estabelecida contra MIA em Aprendizado Federado [Elhattab and Bouchenak, 2023]: o pior caso é o V1 centralizado (0,151), seguido pelo V2 federado (0,124), e o V3 com DP atinge a faixa de $\approx 0,10$–$0,12$. Contudo, com apenas ≈ 74 fraudes no conjunto do atacante, as barras de erro são amplas ($\pm 0,06$ a $\pm 0,11$) e as diferenças *entre* os orçamentos ε não são estatisticamente distinguíveis, e mesmo a diferença V2 vs. V3 está próxima do piso de ruído. O degrau robusto é o do modelo centralizado (pior caso de privacidade) contra as abordagens federadas/privadas. Vale ainda destacar que o mesmo ruído que reduz o ataque é o que degrada a PR-AUC, então privacidade ganha e utilidade perdida são, neste regime de classe rara, dois lados da mesma moeda. Assim, a Hipótese 3 é parcialmente confirmada: a DP reduz a vulnerabilidade (sobretudo frente ao pior caso centralizado), mas a um custo de utilidade real ($\approx 0,15$ de PR-AUC) e com magnitude de redução do MIA limitada pela escassez da classe rara.

5.5. Visualização dos Resultados

Os comportamentos descritos são ratificados visualmente por quatro figuras. A Figura 1 detalha a curva de utilidade (PR-AUC em função de μ), evidenciando o platô em μ baixo e o declínio abrupto em $\mu = 0,1$. A Figura 2 ilustra a atenuação do risco empírico do MIA na classe de fraude. A Figura 3 mostra a dinâmica de convergência da utilidade ao longo das 15 rodadas de federação, evidenciando que o V3 (com DP) converge mais lentamente e para um patamar inferior ao V2. Por fim, a Figura 4 sintetiza o *trade-off*: tanto a utilidade (PR-AUC) quanto o risco empírico do MIA decrescem de V1 para V2 e V3, ilustrando que, neste regime de classe rara, a privacidade ganha caminha junto com a queda de utilidade.

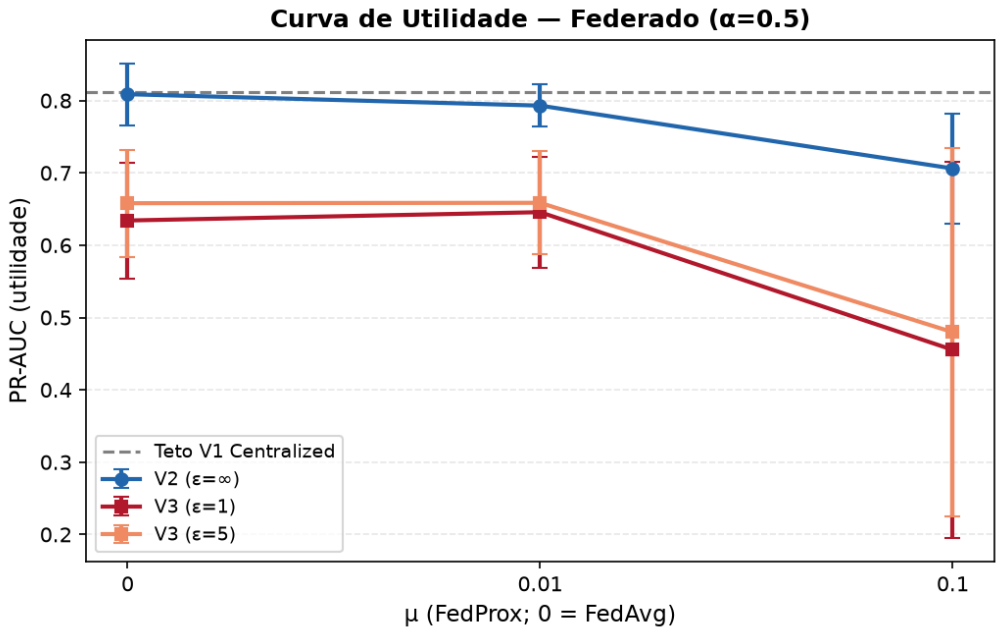


Figura 1: Curva de Utilidade — PR-AUC (Média ± DP) em função do parâmetro proximal μ (FedProx), comparando V2 ($\varepsilon = \infty$) e V3 ($\varepsilon \in \{1; 5\}$), com o teto V1 centralizado. O custo da DP e o colapso em $\mu = 0,1$ são evidentes.

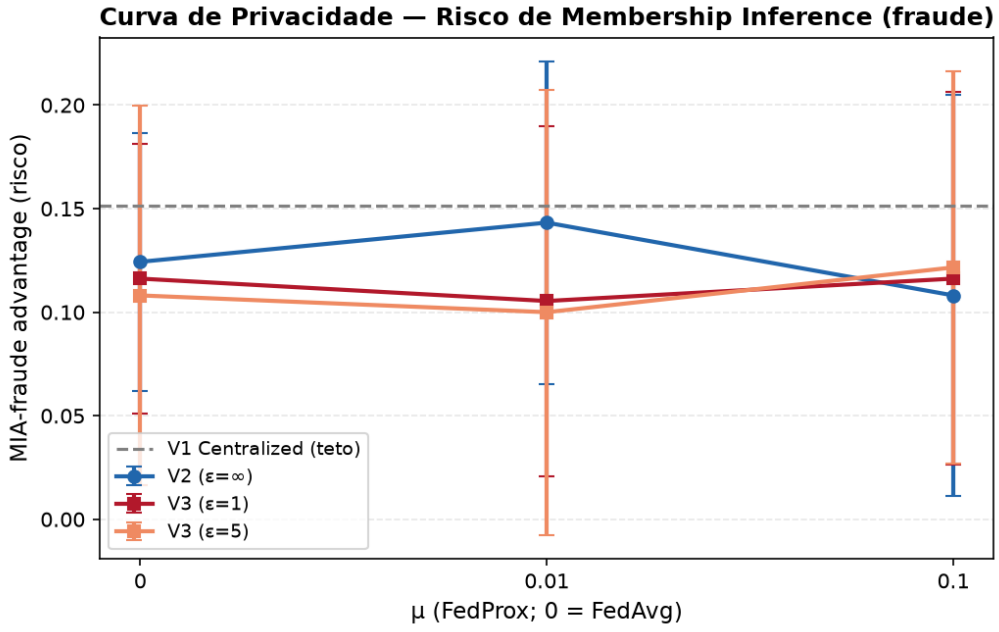


Figura 2: Curva de Privacidade — *Advantage* empírico do MIA restrito à classe minoritária de fraude, em função de μ, para V2 e V3. As amplas barras de erro refletem o piso de ruído estatístico (≈ 74 fraudes).

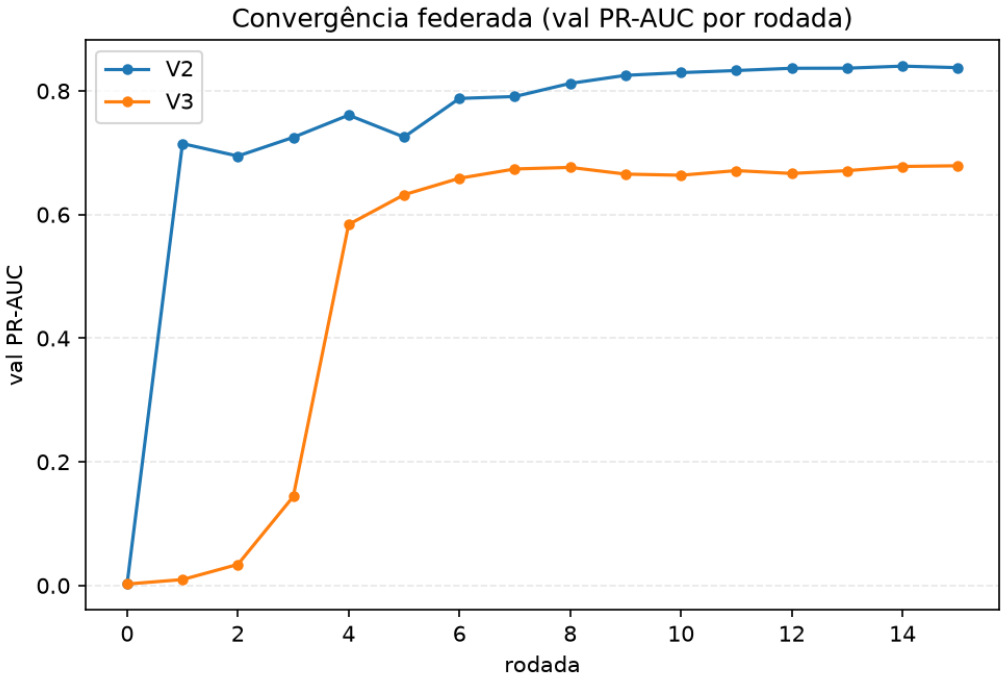


Figura 3: Convergência da utilidade — PR-AUC de validação ao longo das 15 rodadas de federação para V2 (sem DP) e V3 (com DP). O V3 converge mais lentamente e estabiliza em patamar inferior, refletindo o custo do ruído diferencial.

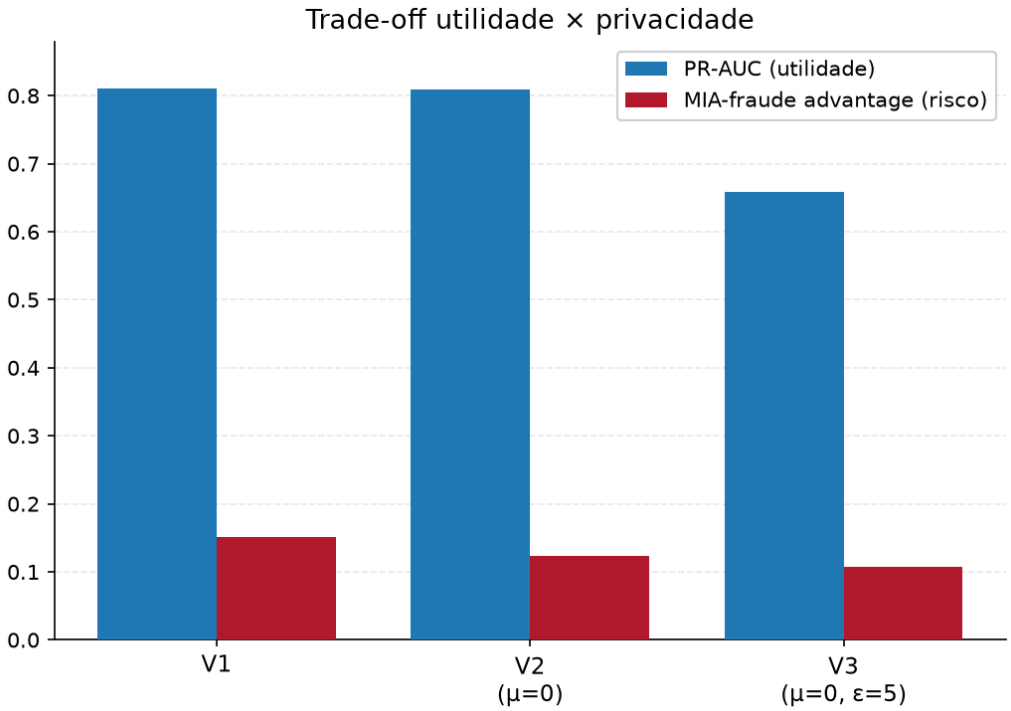


Figura 4: *Trade-off* Utilidade × Privacidade por arquitetura — PR-AUC (utilidade) e *advantage* do MIA-fraude (risco), médias das cinco sementes ($\mu = 0$/FedAvg; V3 no orçamento $\varepsilon = 5$). Tanto a utilidade quanto o risco do atacante decrescem de V1 para V2 e V3.

5.6. Investigação de Caso: O Colapso da Semente 46

Durante as avaliações multi-semente exploratórias, documentou-se que a semente 46 colapsou de forma reprodutível sob privacidade diferencial, exibindo PR-AUC de teste de apenas $\approx 0,003$ em execuções independentes. Por essa razão, a semente 46 foi excluída do conjunto principal, que utiliza as cinco sementes saudáveis. Uma investigação revelou que o fenômeno não constitui falha de implementação, mas a manifestação empírica de um limite documentado na literatura de aprendizado privado.

A semente 46 gerou, pelo sorteio de Dirichlet, a pior partição estatística do estudo, isolando o cliente menor com uma base restrita e quase desprovida de fraudes. No cenário federado puro (V2), o FedAvg ainda extraía conhecimento residual dessa topologia hostil. Sob o V3, contudo, a combinação foi fatal: o tamanho reduzido da base local força a calibração do *back-solving* a adotar um multiplicador de ruído elevado (da ordem de $\sigma \approx 0,8$ para o menor cliente). Os gradientes da classe de fraude nesse nó, já debilitados pela escassez, sofreram achatamento pelo teto do *clipping* ($C = 1$) e foram afogados pela variância gaussiana injetada. A razão sinal-ruído convergiu para zero, transformando os *updates* de fraude em ruído estocástico. O modelo global perdeu a capacidade de estruturar uma fronteira de separação para o sinal raro, colapsando a PR-AUC para a taxa base de aleatoriedade. O evento confirma que a privacidade diferencial atua de forma assimétrica em dados Não-IID desbalanceados: *"O ruído que protege o indivíduo é o mesmo que cega o modelo para o sinal raro"* [Sanyal et al., 2022].

6. Conclusão

Este trabalho estabeleceu um mapeamento experimental do Aprendizado Federado Privado aplicado à detecção de fraudes bancárias tabulares, sob desbalanceamento severo e heterogeneidade Não-IID. Quanto às três hipóteses de trabalho:

- **Hipótese 1 (confirmada):** a federação supera o piso de modelos isolados ($0,809$ vs. $0,727$; ganho pareado $+0,082$, $5/5$ sementes, $p < 0,005$) e iguala o teto centralizado ($0,811$) sem centralizar dados, validando o paradigma colaborativo sob LGPD/GDPR.
- **Hipótese 2 (refutada):** o FedProx não superou o FedAvg; sob uma única época local, o *client drift* é pequeno demais para o termo proximal corrigir, e valores elevados de μ apenas degradaram o aprendizado.
- **Hipótese 3 (parcialmente confirmada):** o DP-SGD reduz a vulnerabilidade ao MIA — sobretudo frente ao pior caso centralizado — ao custo de $\approx 0,15$ de PR-AUC, sendo $\varepsilon \approx 5$ o ponto de operação de engenharia. A magnitude da redução do MIA entre orçamentos, porém, é limitada pela escassez da classe rara e permanece no piso de ruído estatístico.

Por fim, o isolamento do modo de falha da semente 46 fornece uma contribuição relevante, explicitando que salvaguardas de privacidade diferencial exigem o tratamento prévio de heterogeneidades extremas de dados, sob risco de silenciar por completo os sinais raros e valiosos do sistema. Como trabalho futuro, destacam-se a varredura de orçamentos intermediários ($\varepsilon \in \{2, 3, 10\}$) para mapear com maior resolução o *trade-off* utilidade–privacidade, a ampliação do conjunto de fraudes no protocolo de MIA para reduzir a incerteza da medida de privacidade, e a avaliação de ataques mais sofisticados (e.g., *shadow models*).

Referências

Fatima Elhattab and Sara Bouchenak. Mitigating membership inference attacks in federated learning. In *COMPAS'23 : Conférence francophone en informatique*, Annecy, France, July 2023. URL https://hal.science/hal-04124475.

Frederico Gadelha Guimarães. Slides virtuais da disciplina de proteção da privacidade em aprendizado de máquina. Departamento de Ciência da Computação, Universidade Federal de Minas Gerais (UFMG), 2026.

Harshit Gulipalli, Hema Kakarlapudi, Moorathoti Achsah Himavarsha, Ainapuri Sri Nikhith, and Doddi Chandana Gowri. Privacy-preserving fraud detection in digital payments using federated learning. In *Proceedings of the 2026 IEEE International Conference on Emerging Computing and Intelligent Technologies (ICoECIT)*, pages 1–6, 2026. doi: 10.1109/ICoECIT68303.2026.11497318. URL https://ieeexplore.ieee.org/document/11497318/.

Tian Li, Anit Kumar Sahu, Manzil Zaheer, Maziar Sanjabi, Ameet Talwalkar, and Virginia Smith. Federated optimization in heterogeneous networks. In *Proceedings of Machine Learning and Systems (MLSys)*, volume 2, pages 429–450, 2020. URL https://arxiv.org/abs/1812.06127.

Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Aguera y Arcas. Communication-efficient learning of deep networks from decentralized data. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, volume 54 of *Proceedings of Machine Learning Research*, pages 1273–1282. PMLR, 2017. URL https://arxiv.org/abs/1602.05629.

Viraaji Mothukuri, Reza M. Parizi, Seyedamin Pouriyeh, Yan Huang, Ali Dehghantanha, and Gautam Srivastava. A survey on security and privacy of federated learning. *Future Generation Computer Systems*, 115:619–640, 2021. doi: 10.1016/j.future.2020.10.007.

Amartya Sanyal, Yaxi Hu, and Fanny Yang. How unfair is private learning? In *Proceedings of The 38th Conference on Uncertainty in Artificial Intelligence*, volume 180 of *Proceedings of Machine Learning Research*, pages 1739–1748. PMLR, 2022. URL https://openreview.net/forum?id=H2V43wIj5g9.

Reza Shokri, Marco Stronati, Congzheng Song, and Vitaly Shmatikov. Membership inference attacks against machine learning models, 2017. URL https://arxiv.org/abs/1610.05820.

Dawood Wasif, Dian Chen, Sindhuja Madabushi, Nithin Alluru, Terrence J. Moore, and Jin-Hee Cho. Empirical analysis of privacy-fairness-accuracy trade-offs in federated learning: A step towards responsible ai. *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, 8(3):2666–2677, 10 2025. doi: 10.1609/aies.v8i3.36746. URL https://doi.org/10.1609/aies.v8i3.36746.

Samuel Yeom, Irene Giacomelli, Matt Fredrikson, and Somesh Jha. Privacy risk in machine learning: Analyzing the connection to overfitting. In *2018 IEEE 31st Computer Security Foundations Symposium (CSF)*, pages 268–282. IEEE, 2018. doi: 10.1109/CSF.2018.00027. URL https://arxiv.org/abs/1709.01604.

Yue Zhao, Meng Li, Liangzhen Lai, Naveen Suda, Damon Civin, and Vikas Chandra. Federated learning with non-iid data, 2018. URL https://arxiv.org/abs/1806.00582.